停止使用 AdamW，现在大家都在用 Muon

Vuk Rosić，由 Chaoqi Liang 审阅

vukrosic/muon-optimizer-guide

所有人（OpenAI, Meta, DeepSeek, Moonshot AI,...）都已经用 Muon 优化器替代了 AdamW 来训练他们的 LLMs 和神经网络。

DeepSeek 研究员表示，Muon 优化器是 2025 年最大的两项发明之一。

如果你训练任何神经网络 - 你必须尝试它！

它应该让你的训练速度提升 30% 到 2 倍！

Muon 击败 AdamW 的证据

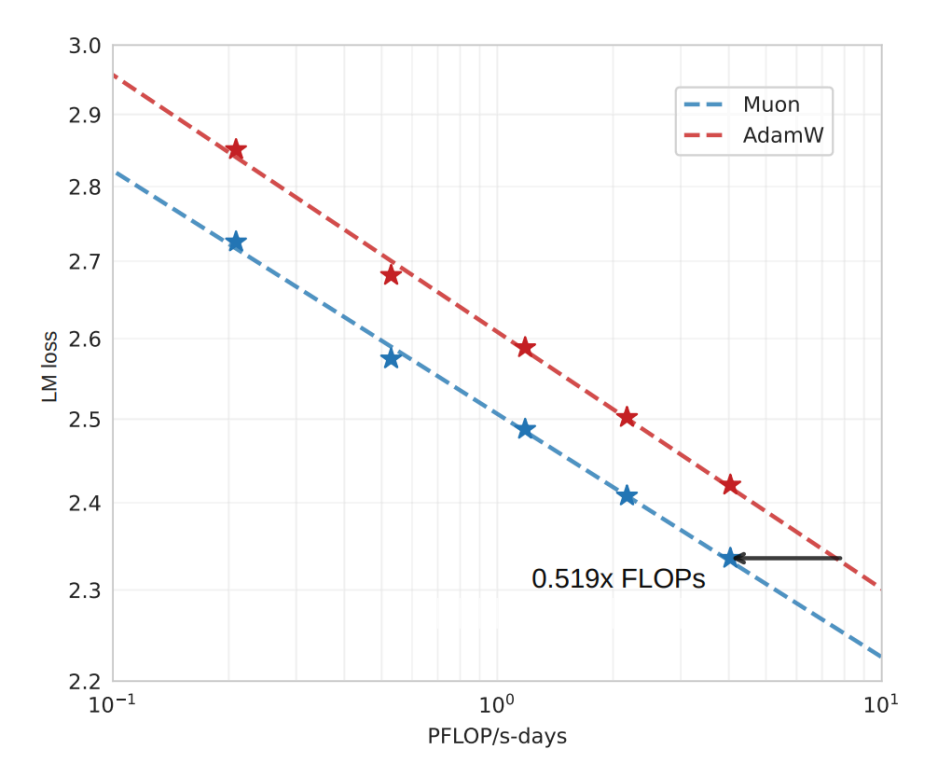

图 1: *Muon 在大规模 LLMs 上非常有效。* [MUON IS SCALABLE FOR LLM TRAINING on arxiv]

不同的优化器以最少的 token 数最快地达到相同的损失：

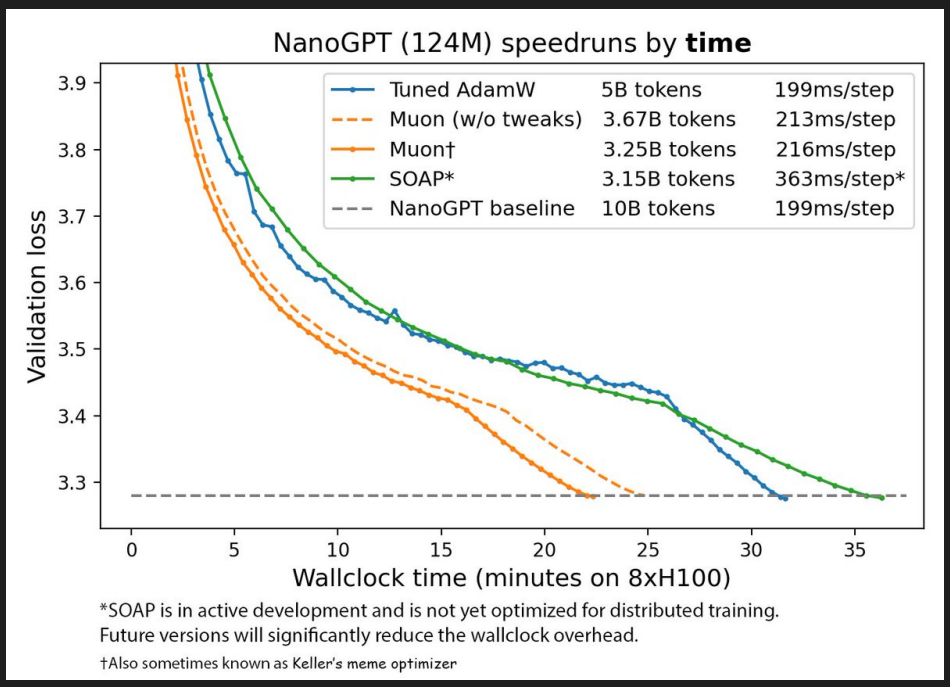

图 2: *更快的 LLM 训练。* [Jordan et al. 2024]

关于代码与实现，请向下滚动查看。

核心思想

如果你是一个初学者，看不懂这些，请将它复制到 Gemini, ChatGPT, Claude, Kimi 等，并让它教你。

让我们从参数更新的基本公式开始：

$$\theta_{t+1} = \theta_t - \eta \cdot \nabla_\theta \mathcal{L}$$

- θ_t: 在第 t 步的模型参数（所有权重）。
- θ_{t+1}: 一次训练步骤后更新的参数。
- η: 学习率（更新步长）。

- $\mathcal{L}$: 损失函数。
- $\nabla_\theta \mathcal{L}$: 损失对参数 θ 的梯度。
- t: 优化步数索引。

如果我们看一下梯度 $\nabla_\theta \mathcal{L}$，这个矩阵减去了权重 - 这就是神经网络学习的方式。然而，这个矩阵可能是病态（ill-conditioned）的 - 一些方向可能有较强的“拉力（pull）”，而其他方向可能有较弱的“拉力”。

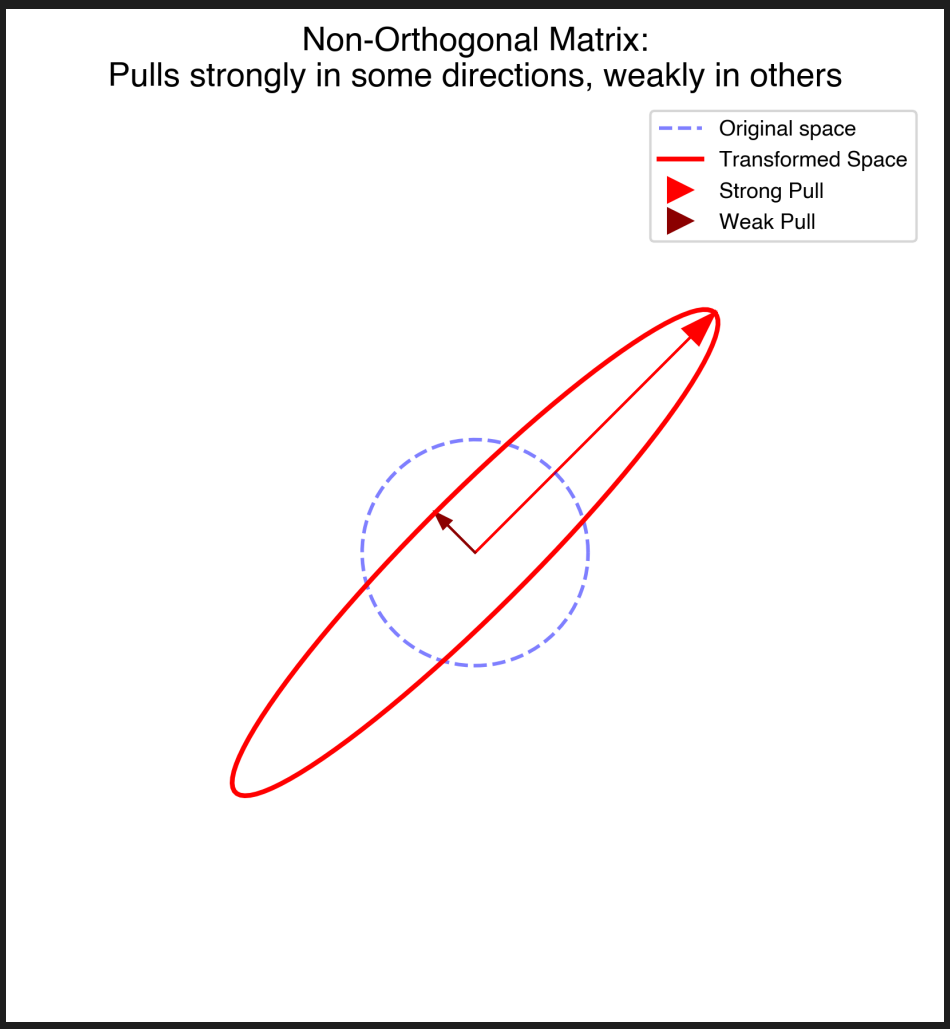

非正交效应 (Non-Orthogonal Effects)

“方向”或“拉力”跨越多个权重的协调变化。它控制了层中的输入 → 输出路径。

例如：假设我们正在训练一个神经网络 - 当它看到许多绿色时，应该预测“草地（grass）”，当它看到许多圆形时，应该预测“轮子（wheels）”。

由于不同类型的图像编码，绿色图像的梯度可能有非常小的奇异值（0.01），而圆形图像的梯度可能有较大的奇异值（100）。

这意味着神经网络学习 [绿色 → 草地] 路径（预测）的速度会比 [圆形 → 轮子] 路径慢得多。

并不是说关于绿色的数据更少或者圆形更重要，而仅仅是因为数据被表示为数字的方式造成的。

Muon 优化器解决了这个问题：

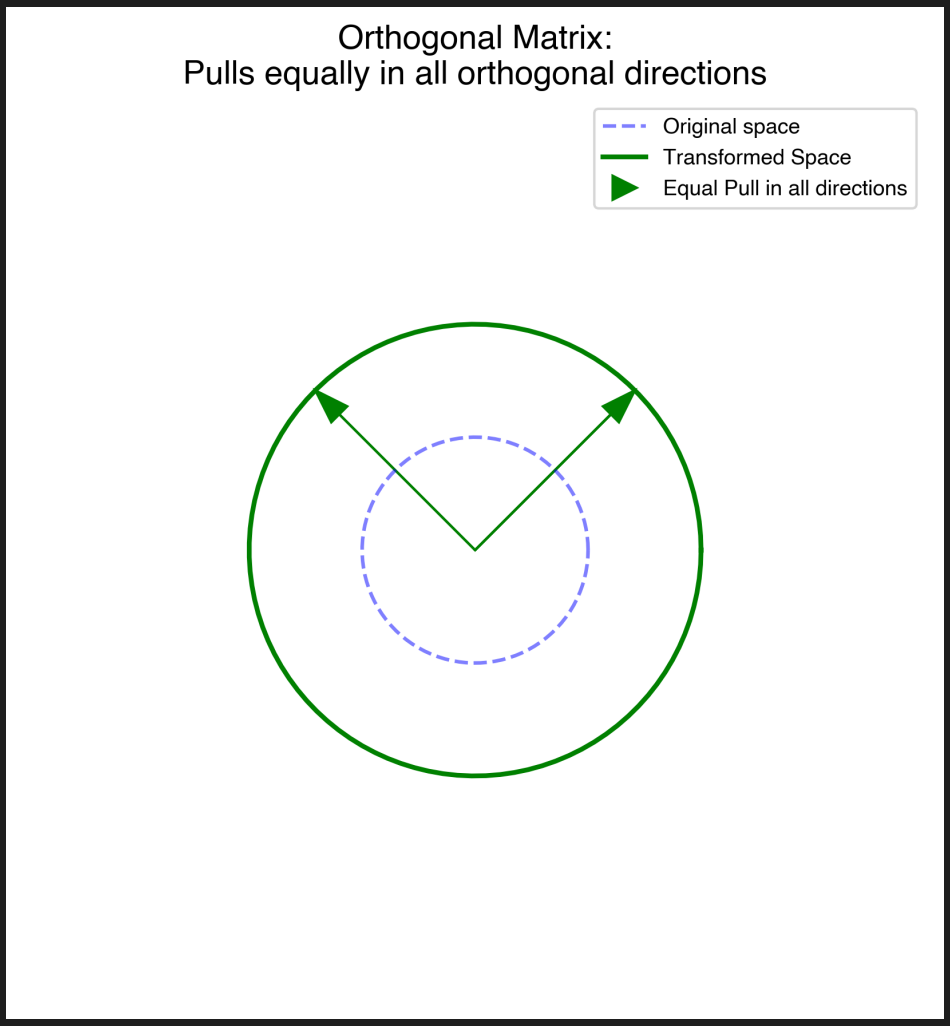

正交效应 (Orthogonal Effects)

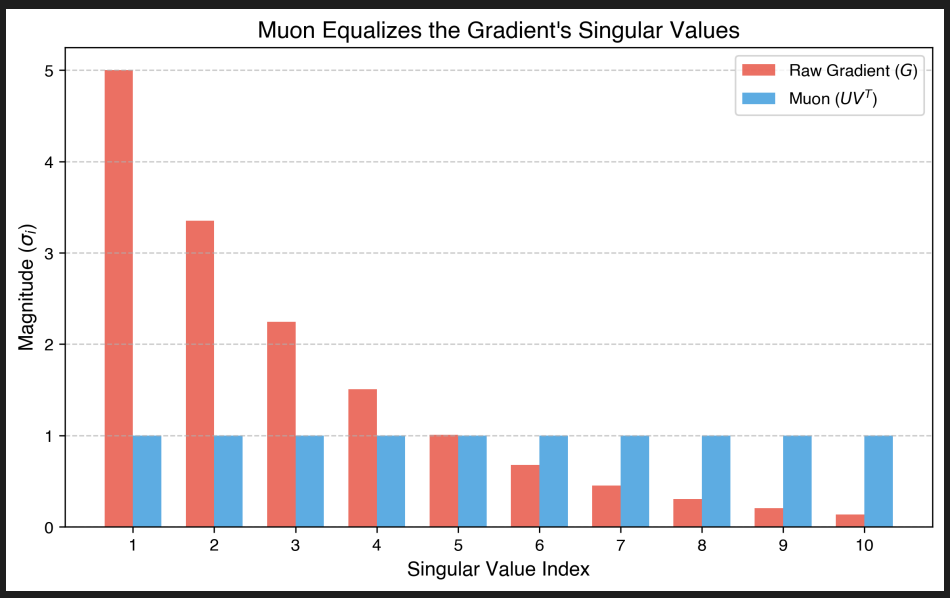

Muon 的 SVD 直觉：原始梯度有不均匀的奇异值，而 Muon 使用带有等化奇异值的 UV^T。

Muon 优化器将使所有的奇异值等于 1（实际上接近 1，为了更快的计算速度），所以它在更新 / 学习 [绿色 → 草地] 路径时的速度将与 [圆形 → 轮子] 路径相同。

重要：仅将 Muon 用于 2D 权重矩阵。不要（Do NOT）将它用于 embeddings, biases, LayerNorms 或最终的输出头（output head）- 请使用 AdamW。

关键区别

Muon 优化器使得**权重更新矩阵（weight update matrices）**正交化，而非权重矩阵本身。

代码与实现 (Code & Implementation)

通过 搜索“muon keller jordan code”可以找到原始的 Muon 代码。

下面我的实现包含了另一项改进 - polar express。你也可以使用上面链接的原始代码，或者我的实现。

如果你将代码复制粘贴到你的 AI 代理中，它应该会自动实现它。

```
import torch

# Polar Express coefficients - each step uses different, pre-optimized (a
    , b, c).
coeffs_list = [
```

```
    (8.156554524902461,  -22.48329292557795,   15.878769915207462),
    (4.042929935166739,  -2.808917465908714,    0.5000178451051316),
    (3.8916678022926607, -2.772484153217685,    0.5060648178503393),
    (3.285753657755655,  -2.3681294933425376,   0.46449024233003106),
    (2.3465413258596377, -1.7097828382687081,   0.42323551169305323),
]

@torch.compile()
def zeropower_polar_express(G: torch.Tensor, steps: int = 5) -> torch.
    Tensor:
    X = G.bfloat16()
    transposed = X.size(-2) > X.size(-1)
    if transposed:
        X = X.mT
    X = X / (X.norm(dim=(-2, -1), keepdim=True) * 1.01 + 1e-7)
    for a, b, c in coeffs_list[:steps]:
        A = X @ X.mT
        X = a * X + (b * A + c * A @ A) @ X
    return X.mT if transposed else X

class Muon(torch.optim.Optimizer):
    def __init__(self, params, lr: float = 0.02, momentum: float = 0.95,
                 weight_decay: float = 0.0):
        super().__init__(params, dict(lr=lr, momentum=momentum,
                                      weight_decay=weight_decay))

    @torch.no_grad()
    def step(self):
        for group in self.param_groups:
            for p in group["params"]:
                if p.grad is None:
                    continue
                state = self.state[p]
                if "buf" not in state:
                    state["buf"] = torch.zeros_like(p.grad)
                buf = state["buf"]
                buf.lerp_(p.grad, 1 - group["momentum"])
                g = p.grad.lerp_(buf, group["momentum"])
                g = zeropower_polar_express(g.view(g.size(0), -1))
                g = g.to(p.dtype)
                if group["weight_decay"] > 0:
                    p.mul_(1 - group["lr"] * group["weight_decay"])
                scale = max(1, p.size(-2) / p.size(-1)) ** 0.5
                p.add_(g.view_as(p), alpha=-group["lr"] * scale)
```

注: 为了快速使用,直接复制粘贴上面的代码即可。如果需要更多控制,请使用 `optimizers/muon.py`。

使用示例 (Usage Example)

```
import torch
import torch.nn as nn

model = MyTransformer().cuda()

muon_params  = [p for p in model.parameters() if p.ndim == 2 and p.
    requires_grad]
adamw_params = [p for p in model.parameters() if not (p.ndim == 2 and p.
    requires_grad)]

optimizer_muon  = Muon(muon_params,  lr=0.02, momentum=0.95)
optimizer_adamw = torch.optim.AdamW(adamw_params, lr=3e-4, weight_decay
    =0.1)

for batch in dataloader:
    loss = model(batch)
    loss.backward()
    optimizer_muon.step()
    optimizer_adamw.step()
    optimizer_muon.zero_grad()
    optimizer_adamw.zero_grad()
```

提示: 一个简单的 `p.ndim == 2` 过滤器能够正确地分离出 Linear 层的权重矩阵。

关键实现提示 (Key Implementation Tips)

使用大尺寸的学习率 (Use a BIG Learning Rate)

不像通常使用 `3e-4` 的 AdamW，Muon 在使用大得多的学习率时表现最佳:

- **默认 (Default):** `0.02`。
- **范围 (Range):** `0.01` 到 `0.05`。

参数路由 (Parameter Routing)

Muon 仅专为 2-D 权重矩阵设计。请将 AdamW 用于所有其他参数上。

编译它！(Compile It!)

为了性能，请使用 `@torch.compile()`。

根据矩阵形状缩放学习率 (Scaling the LR by Matrix Shape)

此更新由 $\sqrt{\max(1, \text{rows}/\text{cols})}$ 缩放。